

Parâmetros de Avaliação dos Prompts Gerados (LLM-as-Judge)

Documento de apoio à Seção de Metodologia da monografia

1. Parâmetros adotados para avaliação

O modelo avaliador (juiz) é o **Claude Opus 5**. Cada prompt gerado pelas SLMs candidatas é avaliado segundo um rubric de seis critérios, pontuados individualmente de 1 a 3 (nota máxima total: 18). Os critérios são formulados de modo domínio-neutro, de forma a serem aplicáveis a benchmarks de naturezas distintas do *Computer Language Benchmarks Game* (físicos, como o problema n-corpos; algorítmicos, como o conjunto de Mandelbrot, o cálculo de dígitos de π ou árvores binárias).

Critério	1	2	3
task_identity	tarefa errada	relacionada mas desviou	benchmark correto, claramente identificado
spec_completeness	falta elemento maior da especificação	parcial	cobre todos os parâmetros/fórmulas necessários à reprodução exata
value_fidelity	valores ausentes ou majoritariamente incorretos	alguns valores corrompidos/alterados	todos os valores numéricos reproduzidos verbatim, sem corrupção
format_compliance	não gerou um prompt (despejou código, ou saída vazia/irrelevante)	gerou prompt mas ignorou a estrutura pedida	seguiu exatamente o formato/estrutura solicitado
output_specification	ausente	vaga	precisa (formato, precisão, argumento)
ambiguity_level	múltiplas interpretações válidas	quase única	interpretação única — dois desenvolvedores produziriam o mesmo artefato

2. Critério de aprovação

Um prompt gerado é considerado **aprovado** quando satisfaz, simultaneamente, duas condições:

1. **Nenhum critério recebe nota 1.** A nota 1 indica uma falha *categórica* — desvio da tarefa, ausência de especificação relevante, corrupção generalizada dos valores fornecidos, geração de código no lugar do texto do prompt, ausência de especificação de saída, ou ambiguidade grave o suficiente para produzir interpretações substancialmente diferentes. Uma falha desta natureza compromete o artefato como um todo e não deve ser compensada por notas altas nos demais critérios.
2. **Pontuação total $\geq 13/18$.** Com seis critérios de nota mínima 2 (uma vez satisfeita a condição anterior), o piso teórico de um prompt sem nenhuma falha categórica é 12 (seis critérios avaliados como "parcial"/"adequado"). Exigir total ≥ 13 assegura que o prompt supere o patamar de mera adequação em ao menos uma dimensão, e não apenas evite falhas graves.

Por que as duas condições são necessárias, e não redundantes: a pontuação total, isoladamente, não distingue um prompt estruturalmente sadio (seis critérios em torno de "adequado", sem falhas graves) de um prompt com uma falha categórica isolada compensada por notas altas nos demais critérios (por exemplo, uma nota 1 e cinco notas 3 somam o mesmo total que seis notas 2). Como uma falha categórica compromete o artefato como um todo, independentemente do desempenho nos demais critérios, a condição "nenhuma nota 1" é indispensável como filtro independente da pontuação total.

Formalmente, seja P um prompt avaliado nos seis critérios do rubric, com notas $c_1, \dots, c_6 \in \{1, 2, 3\}$ e total $T = \sum c_i$. Então:

$$\text{aprovado}(P) \Leftrightarrow (\forall i, c_i \neq 1) \wedge (T \geq 13)$$